

Replikácia súborového modelu na detekciu chorôb listov hrozna pomocou extrakcie príznakov CNN a klasifikátora Random Forest

Kyrylo Slyzhuk *FEI*

TUKE

Košice, Slovensko

Email: kyrylo.slyzhuk@student.tuke.sk

Aleksii Karpliuk *FEI*

TUKE

Košice, Slovensko

Email: oleksii.karpliuk@student.tuke.sk

Abstrakt

Táto správa predstavuje replikáciu štúdie od Ishengoma a Lyima, publikovanej v časopise *Heliyon* (2024), ktorá navrhuje súborový model na detekciu chorôb listov hrozna pomocou konvolučných neurónových sietí (CNN) ako extraktorov príznakov a klasifikátora Random Forest. Pôvodná štúdia sa zameriava na výzvu včasnej detekcie chorôb listov hrozna pri obmedzených dátových súboroch, pričom dosiahla presnosť až 95,34% pomocou dvojkanálovej CNN architektúry. Naša replikácia implementuje hlavnú metodológiu s určitými odchýlkami a porovnáva výsledky s pôvodnými zisteniami.

Index Terms

Choroby listov hrozna, CNN, Random Forest, Súborový model, Klasifikácia obrázkov

I. ÚVOD

Táto správa replikuje výskumný článok „Súborový model na detekciu chorôb listov hrozna pomocou extrakcie príznakov CNN a klasifikátora Random Forest“ od Fariana S. Ishengoma a Neemy N. Lyima, publikovaný v časopise *Heliyon* (2024) [1]. Štúdia sa zameriava na včasnú detekciu chorôb listov hrozna, čo je kľúčový problém pre farmárov, aby sa predišlo značným stratám na úrode. Autori navrhujú súborový model, ktorý kombinuje extraktory príznakov založené na CNN s klasifikátorom Random Forest, aby sa zlepšila klasifikačná výkonnosť pri obmedzených dátových súboroch.

II. ZHRNUTIE VÝSKUMNÉHO ČLÁNKU

A. Popis problému

Článok sa zaoberá výzvou včasnej detekcie chorôb listov hrozna, ktorá je kľúčová pre minimalizáciu strát na úrode. Choroby rastlín môžu spôsobiť až 45% ročnú stratu úrody, ak nie sú včas odhalené [1]. Tradičné metódy hlbokého učenia vyžadujú veľké dátové súbory a rozsiahle tréningy, ktoré často nie sú v poľnohospodárskom kontexte dostupné. Autori si kladú za cieľ vyvinúť model, ktorý dobre funguje pri obmedzených dátových súboroch a zároveň zachováva vysokú presnosť pri klasifikácii chorôb.

B. Metodológia

Navrhovaná metodológia zahŕňa súborový model, ktorý využíva CNN na extrakciu príznakov a klasifikátor Random Forest (RF) na finálnu klasifikáciu. Použitý dátový súbor je PlantVillage Grape, ktorý obsahuje 4062 obrázkov v štyroch triedach: Black-rot, Esca-black-measles, Healthy a Leaf-blight-isariopsis-leafspot. Dátový súbor je rozdelený na tréningovú (70%), validačnú (20%) a testovaciu (10%) množinu, pričom augmentácia bola aplikovaná na vyváženiu triedy Healthy.

Proces predspracovania zahŕňa:

- *Odstránenie pozadia*: Použitie prístupu založeného na neurónových sieťach na elimináciu rušivého pozadia.
- *Priemerovanie intenzity*: Na normalizáciu intenzity obrazu a zníženie variácií.
- *Bilaterálne filtrovanie*: Na vyhladenie obrázkov pri zachovaní hrán, čím sa znižuje šum, ktorý by mohol ovplyvniť klasifikáciu.

Architektúra modelu pozostáva z dvoch konfigurácií:

- *Jednokanálové modely*: Jednotlivé CNN (VGG16, InceptionV3, Xception, ResNet50) extrahujú príznaky, ktoré sú potom podané do klasifikátora RF.
- *Dvojkanálové modely*: Páry CNN (napr. VGG16-Xception) sú prepojené paralelne, aby extrahovali rozmanitejšie príznaky, ktoré sú potom skombinované a podané do klasifikátora RF.

Proces tréovania zahŕňa dve fázy: najprv sa hodnotia jednokanálové modely a najlepšie modely (s presnosťou nad 90%) sa kombinujú do dvojkanálových modelov. Dvojkanálové modely sa potom tréujú a vyhodnocujú.

C. Architektúra modelu

Architektúra je podrobne opísaná nasledovne:

- *Vstup*: Obrázky listov hrozna o veľkosti 256×256 pixelov.
- *Extrakcia príznakov pomocou CNN*: Predtrénované modely CNN (VGG16, InceptionV3, Xception, ResNet50) extrahujú príznaky z obrázkov.
- *Kombinácia príznakov (dvojkanálové)*: V dvojkanálových modeloch sú príznaky z dvoch CNN skombinované, aby vytvorili bohatší súbor príznakov.
- *Klasifikátor Random Forest*: Skombinované príznaky sú klasifikované pomocou klasifikátora RF so 100 rozhodovacími stromami.
- *Výstup*: Model predpovedá jednu zo štyroch tried: Black-rot (Br), Esca-black-measles (Ebm), Healthy (He) alebo Leaf-blight-isariopsis-leafspot (Lbils).

D. Kľúčové výsledky

Autori uvádzajú nasledujúce kľúčové výsledky:

- Jednokanálové modely tréované na modifikovaných obrázkoch (s predspracovaním) dosahujú presnosti 75% (ResNet50), 90% (InceptionV3), 92% (Xception) a 92,16% (VGG16).
- Dvojkanálové modely tréované na modifikovaných obrázkoch dosahujú presnosti až 95,34% (VGG16-Xception), čo predstavuje zlepšenie až o 5,6% oproti jednokanálovým modelom.
- Kroky predspracovania (priemerovanie intenzity a bilaterálne filtrovanie) výrazne zlepšujú výkonnosť modelu tým, že zvyšujú viditeľnosť vzorcov chorôb.

III. ROZDIELY V IMPLEMENTÁCII

Naša implementácia úzko sleduje metodológiu opísanú v pôvodnom článku, ale obsahuje niekoľko odchýlok kvôli praktickým obmedzeniam a optimalizačným rozhodnutiam. Nižšie uvádzame kľúčové rozdiely a ich zdôvodnenia.

A. Rozdelenie dátového súboru a augmentácia

V pôvodnej štúdii je dátový súbor rozdelený na tréovaciu (70%), validačnú (20%) a testovaciu (10%) množinu. Okrem toho sa augmentácia (vertikálne prevrátenie a rotácia o 90 stupňov) aplikuje špecificky na triedu Healthy, aby sa vyvážil dátový súbor, čím sa jej veľkosť zvýšila na približne 1180–1383 obrázkov na triedu. V našej implementácii:

- Dátový súbor sme rozdelili na tréovaciu (70%), validačnú (15%) a testovaciu (15%) množinu.
- Rozsiahlejšiu augmentáciu sme aplikovali na všetky triedy pomocou ImageDataGenerator, s rôznymi parametrami pre náročné triedy (Black-rot a Esca-black-measles), aby sme zlepšili generalizáciu modelu. Presný počet augmentovaných obrázkov na triedu však nebol vypočítaný.

Zdôvodnenie: Rozšírená augmentácia bola implementovaná na zvýšenie robustnosti modelu vo všetkých triedach, nielen v triede Healthy, čo podľa nás zlepšuje generalizáciu, ale odchyľuje sa od prístupu článku. Chýbajúce presné počty augmentovaných obrázkov obmedzujú priame porovnanie s vyváženým dátovým súborom pôvodnej štúdie.

B. Kroky predspracovania

Článok využíva tri kroky predspracovania: odstránenie pozadia (pomocou prístupu založeného na neurónových sieťach), priemerovanie intenzity a bilaterálne filtrovanie. V našej implementácii:

- Odstránenie pozadia sme implementovali pomocou farebného priestoru HSV a maskovania namiesto metódy založenej na neurónových sieťach.
- Priemerovanie intenzity bolo implementované pomocou rozmazania s 3×3 oknom.
- Bilaterálne filtrovanie bolo implementované s parametrami $d = 9$, $\sigma_{\text{Color}} = 75$ a $\sigma_{\text{Space}} = 75$.

Zdôvodnenie: Odstránenie pozadia pomocou HSV bolo zvolené ako jednoduchšia alternatíva k metódam založeným na neurónových sieťach (napr. rembg), ktoré vyžadujú dodatočné závislosti a výpočtové zdroje. Priemerovanie intenzity a bilaterálne filtrovanie boli implementované, aby zlepšili viditeľnosť vzorcov chorôb, ako to bolo navrhnuté v pôvodnej štúdii, ale s použitím zjednodušených metód na zníženie výpočtovej náročnosti.

C. Veľkosť obrázkov

Pôvodná štúdia používa obrázky o veľkosti 256×256 pixelov. V našej implementácii:

- Obrázky boli zmenšené na 128×128 pixelov počas tréovania (`main.py`).

Zdôvodnenie: Zmenšili sme veľkosť obrázkov, aby sme znížili spotrebu pamäte a urýchlili tréovanie, pretože spracovanie obrázkov veľkosti 256×256 bolo na našom hardvéri výpočtovo náročné. Táto redukcia mohla viesť k strate jemných detailov, čo mohlo potenciálne ovplyvniť presnosť modelu, hoci naše výsledky naznačujú opak.

D. Výber klasifikátora

Článok používa klasifikátor Random Forest (RF) so 100 rozhodovacími stromami. V našej implementácii:

- RF sme nahradili XGBoost, ktorý bol nakonfigurovaný so 100 estimátormi, maximálnou hĺbkou 4 a rýchlosťou učenia 0,2.

Zdôvodnenie: XGBoost bol zvolený namiesto RF, pretože zvyčajne ponúka lepší výkon pri nevyvážených dátových súboroch a rýchlejšie časy tréovania vďaka svojej gradientnej boostingovej štruktúre. Tieto parametre boli vybrané na optimalizáciu výkonu, čo pravdepodobne prispelo k našej zlepšenej presnosti, hoci sa to odchyľuje od pôvodnej metodológie.

E. Implementácia dvojkanálovej architektúry

Článok opisuje dvojkanálovú architektúru, kde dve CNN (napr. VGG16 a Xception) pracujú paralelne a ich príznaky sa pred klasifikáciou kombinujú. V našej implementácii:

- Príznaky sme extrahovali z VGG16 a Xception oddelene a potom ich skombinovali, ale nevykonali sme explicitnú paralelnú dvojkanálovú architektúru, ako bolo opísané.

Zdôvodnenie: Kombinácia príznakov dosahuje podobný efekt ako dvojkanálová architektúra, pretože skombinované príznaky sú podané do klasifikátora. Paralelná architektúra v pôvodnej štúdii však mohla poskytnúť rozmanitejšie príznaky simultánnemu spracovaniu. Náš prístup zjednodušuje implementáciu tým, že sa vyhýba potrebe rámca pre paralelnú prácu, čo bolo považované za zbytočné vzhľadom na funkčnú ekvivalenciu.

IV. POROVNANIE VÝSLEDKOV

Táto časť porovnáva výkonnosť nášho replikovaného modelu s výsledkami uvedenými v pôvodnom článku. Model hodnotíme pomocou presnosti, precíznosti, návratnosti a F1-skóre, ako to bolo vykonané v pôvodnej štúdii, a predstavujeme maticu zámen na analýzu chýb klasifikácie.

A. Metrika výkonnosti

Tabuľka I predstavuje metriku klasifikácie pre náš model na testovacej množine. Model dosahuje celkovú presnosť 95,2%, s vysokou precíznosťou, návratnosťou a F1-skóre vo všetkých triedach.

Tabuľka I
CLASSIFICATION METRICS OF OUR MODEL

Class	Precision	Recall	F1-score	Support
Black-rot	0.91	0.96	0.93	150
Esca-black-measles	0.96	0.90	0.93	150
Leaf-blight-isariopsis-leafspot	1.00	1.00	1.00	75
Healthy	1.00	1.00	1.00	63
Accuracy		0.952		438
Macro average	0.97	0.97	0.97	438
Weighted average	0.95	0.95	0.95	438

B. Matica zámen

Tabuľka II ukazuje maticu zámen pre náš model. Diagonálne prvky predstavujú správne klasifikované inštancie, zatiaľ čo mimodiagonálne prvky označujú nesprávne klasifikácie. Model funguje dobre, pričom väčšina chýb sa vyskytuje medzi triedami Black-rot a Esca-black-measles, pravdepodobne kvôli vizuálnej podobnosti vzorcov chorôb.

Tabuľka II
MATICA ZÁMEN NÁŠHO MODELU

	Br	Ebm	Lbils	He
Br	144	6	0	0
Ebm	15	135	0	0
Lbils	0	0	75	0
He	0	0	0	63

Poznámka: Br: Black-rot, Ebm: Esca-black-measles, Lbils: Leaf-blight-isariopsis-leafspot, He: Healthy.

C. Porovnanie s pôvodnou štúdiou

Pôvodná štúdia uvádza maximálnu presnosť 95,34% pre dvojkanálový model VGG16-Xception na modifikovaných obrázkoch (s plným predspracovaním), zatiaľ čo jednocanálové modely dosiahli presnosti 75% (ResNet50), 90% (InceptionV3), 92% (Xception) a 92,16% (VGG16). Na rozdiel od toho náš model dosahuje presnosť 95,2%, čo je o 0,14% menej, než dvojkanálový model pôvodnej štúdie. Jednocanálové modely sme samostatne nehodnotili, ale naša dvojkanálová implementácia (skombinované príznaky VGG16 a Xception) prekonáva najlepšie jednocanálové modely pôvodnej štúdie (95,2% oproti 92,16% pre VGG16).

Toto porovnanie možno pripísať viacerým faktorom:

- *Použitie XGBoost*: XGBoost, ktorý sme použili namiesto Random Forest, je známy lepším spracovaním nevyvážených dátových súborov a rýchlejšou konvergenciou, čo potenciálne viedlo k zlepšenému výkonu.
- *Rozšírená augmentácia*: Aplikovali sme augmentáciu na všetky triedy, nielen na triedu Healthy, čo pravdepodobne zlepšilo schopnosť modelu generalizovať.

Naša implementácia obsahuje priemerovanie intenzity a bilaterálne filtrovanie, ktoré pôvodná štúdia označila za kľúčové pre zlepšenie viditeľnosti vzorcov chorôb. Pôvodná štúdia uvádza, že tieto kroky predspracovania zlepšili presnosť až o 5% v porovnaní s nemodifikovanými obrázkami (napr. presnosť VGG16 sa zvýšila z 87,16% na pôvodných obrázkoch na 92,16% na modifikovaných obrázkoch). Naše použitie menších veľkostí obrázkov (128×128 pixelov pre tréning) v porovnaní s 256×256 pixelmi v pôvodnej štúdii mohlo ovplyvniť presnosť, čo pravdepodobne je príčinou mierneho poklesu presnosti v porovnaní s pôvodnou štúdiou. Matica zámen ďalej potvrdzuje vysoký výkon s minimálnymi nesprávnymi klasifikáciami, najmä medzi vizuálne podobnými triedami (Black-rot a Esca-black-measles).

V. KRITICKÁ ANALÝZA A NÁVRHY NA ZLEPŠENIE

A. Kritická analýza

Naša replikácia ukazuje niekoľko silných a slabých stránok v porovnaní s pôvodnou štúdiou.

Silné stránky:

- *Vysoká presnosť*: Náš model dosiahol presnosť 95,2%, čo je veľmi blízko k pôvodnej štúdii (95,34%). Toto je spôsobené použitím XGBoost, ktorý je efektívnejší pri nevyvážených dátových súboroch, a rozšírenou augmentáciou aplikovanou na všetky triedy, čím sa zlepšila generalizácia modelu.
- *Úplné predspracovanie*: Implementácia priemerovania intenzity a bilaterálneho filtrovania zlepšila viditeľnosť vzorcov chorôb, čo prispelo k vysokej presnosti a umožnilo modelu efektívne detegovať jemné vzorce chorôb.

Slabé stránky:

- *Zmenšená veľkosť obrázkov*: Použitie obrázkov s nižším rozlíšením (128×128 pre tréning) mohlo obmedziť schopnosť modelu detegovať jemné vzorce chorôb, čo pravdepodobne viedlo k miernemu poklesu presnosti v porovnaní s pôvodnou štúdiou.
- *Zjednodušená dvojkanálová architektúra*: Naša sekvenčná kombinácia príznakov VGG16 a Xception namiesto paralelnej dvojkanálovej architektúry opísanej v pôvodnej štúdii mohla znížiť rozmanitosť extrahovaných príznakov, čo mohlo ovplyvniť výkon.

B. Návrhy na zlepšenie

Na výrazné zvýšenie schopností modelu a rozšírenie jeho použiteľnosti navrhujeme nasledujúce globálne zlepšenia:

- *Hybridná CNN-GNN architektúra s federatívnym učeníím*: Navrhujeme vytvoriť hybridnú architektúru, ktorá kombinuje CNN a grafové neurónové siete (GNN). CNN by extrahovali priestorové príznaky (textúry a vzorce chorôb), zatiaľ čo GNN by modelovali štruktúrne vzťahy na liste (napr. vzťahy medzi škvrkami choroby a žilkami listu), reprezentované ako graf. Tento prístup by mohol výrazne zlepšiť presnosť klasifikácie, najmä pre vizuálne podobné triedy, ako sú Black-rot a Esca-black-measles, a prekonal by obmedzenia oboch implementácií, ktoré sa spoliehajú iba na CNN. Navyše, zavedenie federatívneho učenia by umožnilo trénovať model na distribuovaných dátových súboroch od rôznych fariem

bez centralizácie údajov, čím by sa zabezpečila ochrana súkromia a zvýšila škálovateľnosť modelu pre reálne nasadenie v poľnohospodárstve.

- *Zavedenie mechanizmov pozornosti:* Integrácia mechanizmov pozornosti, ako je Convolutional Block Attention Module (CBAM) alebo vrstvy pozornosti založené na Transformer architektúre, do CNN architektúry by mohla umožniť modelu sústrediť sa na najdôležitejšie časti obrázka (napr. oblasti postihnuté chorobou). To by mohlo zlepšiť presnosť klasifikácie, najmä pre vizuálne podobné triedy, ako sú Black-rot a Esca-black-measles.
- *Použitie Generatívnych Adversariálnych Sietí (GAN) na augmentáciu:* Namiesto štandardnej augmentácie cez ImageDataGenerator by sa mohli použiť GAN (napr. StyleGAN alebo CycleGAN) na generovanie nových syntetických obrázkov listov hrozna. To by bolo obzvlášť užitočné pre triedy s menším počtom dát, ako je Leaf-blight-isariopsis-leafspot, a mohlo by zlepšiť generalizačnú schopnosť modelu.
- *Integrácia časovej analýzy na monitorovanie chorôb:* Rozšírenie funkcionality modelu o časovú analýzu: namiesto klasifikácie jednotlivých obrázkov by sa mohli analyzovať sekvencie obrázkov jednej rastliny na sledovanie progresie choroby. To by vyžadovalo integráciu rekurentných neurónových sietí (RNN) alebo 3D-CNN na spracovanie časových dát.
- *Vývoj mobilnej aplikácie:* Vytvorenie mobilnej aplikácie (napr. na Flutter alebo React Native) by farmárom umožnilo fotografovať listy priamo pomocou telefónu a získavať predpovede v reálnom čase. To by urobilo riešenie dostupnejším pre používateľov v teréne.
- *Zvýšenie rozlíšenia obrázkov:* Zvýšenie veľkosti obrázkov, napríklad na 200×200 pixelov alebo na maximálne dostupné rozlíšenie, by mohlo výrazne zlepšiť presnosť modelu. Väčšie obrázky umožňujú lepšie zachytenie jemných detailov vzorcov chorôb, čo je kľúčové pre presnú klasifikáciu, najmä pri vizuálne podobných triedach, ako sú Black-rot a Esca-black-measles. Preto odporúčame používať maximálne dostupné rozlíšenie obrázkov, ak to hardvérové možnosti dovoľujú.

VI. LITERATÚRA

LITERATÚRA

- [1] F. S. Ishengoma a N. N. Lyimo, "Súborový model na detekciu chorôb listov hrozna pomocou extrakcie príznakov CNN a klasifikátora Random Forest," *Heliyon*, zv. 10, č. 13, s. e33377, 2024. [Online]. Dostupné: <https://doi.org/10.1016/j.heliyon.2024.e33377>